

用算力平台构建自己的科研智能体：IR-RS-Agent 实践说明

整理日期 2026-09-06

项目定位 个人科研项目；以红外检测为核心，接入分割等视觉工具

状态依据 项目流程与 Qwen 已在算力平台运行复现

代码仓库 https://github.com/ksqwei0605-cloud/ir_rs_agent

1 故事的中心：科研需求如何变成一个能用的系统

项目的起点是一个具体问题：面对不同来源的红外图片，如何按需求完成目标搜索、定位、统计和解释？

卫星海面上的船可能只有很少几个像素，航拍道路上的车辆和行人又具有不同的尺度和背景。只选择一个模型，无法自动解决所有场景；即使已有多个模型，每次手工选择程序、填写参数、寻找结果文件，也会增加使用成本。

研究由此形成了三个相互衔接的层次：

层次	要解决的问题	本项目的做法
专业能力	图片中的目标在哪里、是什么、有多少	训练、筛选并封装不同场景的检测工具
任务组织	用户这次要做什么，应使用哪个工具	Qwen 理解指令、选择工具、依据返回结果作答
计算执行	模型在哪运行，环境和结果怎样管理	算力平台提供计算资源、共享存储和作业管理

最终面向用户的是一个网页：上传图片、输入需求、查看结果、继续追问。支撑网页的是一套可维护的科研流程。

适合对外表述：“我全程基于算力平台开展个人红外分析项目并完成运行复现，进一步把专业模型组织成可交互的科研智能体。”

这句话同时交代研究对象、平台使用和应用成果，不需要改写前期实验发生的时间与环境。

2 算力平台的必要性在哪里

2.1 承载训练和模型推理

训练时需要保存特征、梯度和优化器状态，资源开销不同于只加载权重进行预测。智能体运行时又需要大模型推理、图像预处理、视觉工具和结果生成，不能仅用某个 YOLO 权重文件的大小估算全部需求。

算力平台让研究者根据任务申请 GPU、CPU 和内存。对于个人电脑显存不足的情况，可以在远端计算资源上运行模型，在本地浏览器查看结果。

这是一种降低本地硬件门槛的方式。具备足够硬件的本地工作站同样可以运行项目；平台的价值还包括环境管理、共享存储和作业记录。

2.2 保存可以复查的实验过程

科研结果应能回答：用了哪个权重、哪个输入、什么参数、在哪次运行中得到？

本项目将模型版本、数据划分、参数、可视化结果和运行记录对应起来。在平台上，作业编号、分区、节点、时间与退出状态成为补充信息，可以进一步追溯一次计算。

Slurm 提供作业记录，但不会自动保存模型版本、检测结果或训练检查点。这些内容仍由项目程序和归档流程负责。

2.3 让模型工具和交互应用协作

Qwen 负责理解与表达，视觉工具负责专业计算。平台为二者提供运行条件，网页则把复杂计算转换成用户可操作的界面。

在已获得资源、服务运行且网络访问配置完成的前提下，使用者不必在自己的电脑安装全部深度学习环境。

3 从普通 GPU 服务器到算力平台：相同点与适配点

3.1 可以复用的部分

两种环境都可以提供 Linux、NVIDIA GPU 和 Python 深度学习运行条件。因此，经过兼容性检查后，可以复用数据、模型权重、预处理逻辑、检测代码、工具接口、Agent 逻辑和前端设计。

算力平台不会自动改变模型算法。模型精度仍取决于训练、数据、预处理和评估协议；平台的贡献是承接计算并改善资源与运行过程的组织方式。

3.2 不能只替换名称的部分

方面	原来的使用习惯	算力平台上的适配方式
连接入口	直接连接一台 GPU 主机	通过 SCOW 或获授权的 SSH 入口进入平台
计算位置	登录主机后直接运行模型	登录节点准备和提交任务；GPU 计算在获分配的计算节点执行
权限	原环境可使用 root	使用普通用户环境，不依赖 sudo 或系统目录写入
资源选择	租用时选定一台机器	作业中填写 GPU、CPU、内存、时间，并满足账户与 QoS 权限
等待	主机可用时直接启动	作业可能排队，要区分排队、运行和失败
数据路径	原项目使用专有数据盘绝对路径	改为用户共享工作目录或配置项，不沿用原主机目录
环境	复用实例预装环境	通过 module、Conda、venv 等配置并核验依赖
临时文件	容易假定所有目录都可持续使用	/tmp 等为节点本地目录；重要产物保存在共享目录
Web 服务	主机开着即可长期运行	服务受作业分配和时限约束，作业结束后需重新申请资源启动
网络	隧道直接指向原主机端口	根据实际计算节点及监听地址配置授权代理或隧道
记录	程序日志和手工截图	增加 JobID、作业状态、资源分配、运行时间等记录
扩容	更换主机配置	按权限申请不同分区资源；多卡收益仍需程序支持

尤其要分清：平台登录节点与运行模型的计算节点不是同一概念。原来“连接某台主机的 7860 端口”不能不加修改地套用到平台登录节点。

共享存储也不等于自动备份；应保留需要长期保存的独立副本。

3.3 按教程可以明确介绍的平台特点

- SCOW 提供浏览器入口、文件操作、终端和作业管理能力。
- Slurm 负责分配资源和管理计算作业。
- 培训材料列出了 P107-RTX5090 与 P107-A100 比赛分区；具体可用资源和配额以运行时查询为准。
- 教程列出的 `/public/home/< 用户名 >` 等目录用于共享存储；公共软件通过 `module` 管理。
- `sinfo` 查看分区，`sbatch` 提交作业，`squeue` 查看状态，`sacct` 查询历史记录。
- 平台 GPU 集群、CPU 虚拟机和学校的大模型 API 服务是不同资源。

4 项目的完整实践过程

第一步：先确定实际要做的科研任务

我先把红外分析需求拆成两个主要场景：卫星海面微小船舶检测，以及航拍和地面红外多类别检测。输入不同，工具也可以不同；对用户统一入口。**这一阶段的产物：**任务定义、输入要求、输出形式和验收案例。

第二步：形成专业模型资产

卫星船舶路线通过前期 YOLO 系列实验，选择 YOLOv8 模型作为工具基础。航拍及地面路线使用 HIT-UAV、AIRST-CS、RGBT-Tiny 等数据开展红外适配，形成 YOLO-World 多类别检测模型。训练好的权重绑定类别顺序、输入尺寸、阈值、版本和评估说明。**这一阶段的产物：**模型、配置、数据划分、实验指标和可视化样例。

第三步：把资产接入算力平台

在平台用户空间组织代码、权重、依赖和输入，核验路径和文件完整性。先让一张图的推理跑通，再验证批量处理和多个工具。**这一阶段的产物：**可复用环境、路径配置、最小运行样例。

第四步：将计算组织成可记录的作业

通过 Slurm 描述运行入口和资源需求。项目目录已有检测工具复测模板，申请参数是 1 块 GPU、8 个 CPU 核、32 GB 内存、1 小时时限。**这一阶段的产物：**作业脚本、运行日志、资源记录和对应结果。

第五步：让 Qwen 调用专业工具

将检测、分割等程序封装成清晰接口。工具选择与参数校验缺一不可；条件视觉路由将图像理解用于确有需要的任务判断。**这一阶段的产物：**工具清单、参数约定、路由逻辑、错误处理与测试案例。

第六步：做成能持续使用的界面

网页提供图片上传、自然语言输入、结果图、统计和简洁分析。批量任务支持整体结果与逐图复核；会话允许继续追问；输出可以导出保存。**这一阶段的产物：**完整演示流程、历史记录、批量结果与导出文件。

第七步：在平台复现并形成交付

完整系统与 Qwen 已在平台完成运行复现。平台验证宜同时包括工具成功、Agent 成功与资源使用三个方面。**这一阶段的产物：**部署程序、使用说明、演示视频、平台运行数据说明。

5 两种调度怎样配合

研究者准备代码、模型、数据

↓

通过 Slurm 申请计算资源

↓

计算节点运行智能体后端和模型

↑

用户通过授权访问方式打开网页

↓

图片 + 自然语言需求

↓

Qwen 理解需求 / 必要时结合图像

↓

选择检测、分割等专业工具

↓

返回结构化结果、结果图与自然语言回答

↓

保存会话、实验结果和运行记录

Slurm 的调度对象是计算作业；Agent 的路由对象是专业工具。不能因为项目使用 Slurm，就声称 Agent 已经具备自主申请 GPU、预测排队时间或自动扩缩容能力。

交互服务可以在一个获分配资源的作业内驻留，再处理多轮请求。无需为了每一句追问都重新提交一个 Slurm 作业。服务驻留时间、并发量和资源释放方式仍需符合平台规则。

6 其他同学可以照着走的六步范式

步骤	要完成什么	最小验收标准
1. 定义需求	选一个具体科研问题,说明输入和预期输出	有一条可以实际测试的任务指令
2. 整理资产	准备程序、数据、模型、依赖和使用来源	有一个能独立执行的专业工具
3. 平台运行	配置环境, 申请资源, 提交任务	有对应作业日志与有效结果
4. 工具封装	统一参数、输出与错误格式	用明确输入稳定调用工具
5. 智能体接入	接入大模型路由、结果解释和网页	自然语言能够触发正确任务闭环
6. 验证交付	做测试、保留证据、准备部署材料	别人按说明能重复一次运行

例如, 另一个项目可以把红外检测器替换为细胞计数工具、实验曲线拟合程序或材料性质预测模型。需要重新确定专业输入输出和验证方法, 但环境准备、作业执行、工具封装和交互设计的组织方式可以复用。

7 视频里如何突出平台价值

不够具体的表达	更适合本项目的表达
平台算力很强	平台承接 Qwen 和视觉工具运行，本地电脑主要负责交互
使用了先进集群	通过作业申请 GPU、CPU 和内存，在计算节点执行任务
系统能自动处理一切	系统根据输入与工具能力完成已支持任务，并返回可复核结果
大幅提升效率	展示一次批量处理、结果追问和导出，具体提速比例由实测支持
实现端到端闭环	输入图片与指令后，完成路由、计算、统计、回答和保存
可广泛推广	提供六步参考路径，并说明其他项目需要替换哪些工具和数据

8 运行证据怎样和故事对应

想说明的内容	对应证据	不能单靠什么证明
使用了比赛平台	本人作业记录及分区信息	平台首页截图
检测工具成功运行	无错误的工具结果、框图、输入与权重配置	Python 进程退出码为 0
Qwen 在平台运行	模型加载日志、实际推理日志与对应作业信息	权重目录存在
完整 Agent 跑通	一次请求的路由、工具返回、最终回答和前端结果	单独执行检测脚本
资源配置合理	对应作业的内存、显存和耗时记录	整节点的总使用率
批量结果有效	输入数量、成功失败数及逐图结果	进度条到达 100%

可在提交材料填写：JobID、分区、节点、GPU 型号、资源申请、实际起止时间、应用

日志路径、模型版本、输入数量和成功失败数量。暂缺某个字段就按实际记录说明，不用示意数字填充。

9 本目录旧脚本与最终版本的区别（内部整理备注）

本轮已阅读两份 PDF、两份 DOC、SSH DOCX、两份粘贴文本、环境探测脚本、`reproduce_107` 文本代码；核对了 `stage` 中重复脚本与压缩包文件清单。旧文件能说明早期平台适配思路，但不是负责人刚确认的完整新版部署包，要点如下：

- `infer_batch.py` 明确是三个检测工具复测，不调用 Qwen 或 FastAPI。
- 旧卫星工具仍为三个波段路径输入；最终网页的单张合成图输入应以新版为准。
- 根目录与 `stage` 的 `slurm_infer.sh` 不一致；交付包应统一到实际通过测试的版本。
- 旧批量脚本会捕获工具异常后继续结束，退出码 0 不能单独证明三个工具全部成功，需检查 `summary.json` 的各工具结果。
- 作业脚本使用脚本自身目录定位项目，在 Slurm 暂存脚本情形下不稳妥；应明确工作目录，例如使用已验证的共享项目路径或 `SLURM_SUBMIT_DIR`。

正式提交程序应使用本次已经跑通的新版，不把旧复测包直接当成完整智能体包。

10 资料索引

1. `training-107-competition.pdf`: 平台架构、环境、共享目录、SSH、分区、Slurm、SCOW 与监控。
2. `算力平台及算力赛道介绍.pdf`: 平台用途、Slurm 入门、学科应用选题。
3. “一〇七杯”算力与智能体开发大赛技术支持常见 Q&A (1).doc: 平台权限、分区、API 与 CPU 虚拟机区别。
4. “一〇七杯”算力与智能体开发大赛作品提交预通知.doc: 演示视频、部署文件、作品简介和平台运行数据要求。
5. SSH 权限开放参考操作 (1).docx: SSH 公钥与动态验证码流程。
6. `pasted (1).txt`、`pasted (2).txt`: 比赛方向与平台定位。
7. `reproduce_107/`: 早期平台复测及证据采集脚本。
8. `.../智能体/云服务器在红外智能体项目中的作用说明.md`: 既有科研过程、实验与工程能力。

9. 项目负责人本轮补充：完整流程和 Qwen 已在算力平台完成运行复现。

推荐把视频与本文配套提交：视频说明“为什么做、如何做、能做什么”，本文说明“平台承担什么、别人如何复用”。