

IR-RS-Agent 设计文档

作品名称 IR-RS-Agent ——基于算力平台的红外遥感处理智能体

参赛赛道 算力平台赛道

文档性质 作品设计文档（对应“作品提交预通知”第 1 项）

提交日期 2026-09-06

代码仓库 https://github.com/ksqwei0605-cloud/ir_rs_agent

1 作品概述

IR-RS-Agent 是一个面向开放环境的红外遥感处理智能体。用户以自然语言下达指令，上传单张或批量红外/遥感图像，系统自主理解任务意图、选择并调度专用视觉工具（检测、分割），完成图像分析，并以“自然语言结论 + 结果图 + 结构化数据”的形式反馈，支持连续追问、批量综合分析、结果导出与历史会话。

本作品全程基于中国科学技术大学本科算力平台（107.ustc.edu.cn）开展：大语言模型负责意图理解与结果表达，专用视觉模型负责可靠的检测与分割，算力平台则承接计算、存储、作业调度与运行记录，三者共同构成一个可交互、可复核、可复用的科研智能体。

2 设计思路

2.1 问题定义

不同来源的红外影像需要不同的分析工具，且输入差异显著：

- **无人机/地面红外图**：目标类别多（行人、车辆、自行车、舰船、飞机等），尺度与背景变化大；
- **卫星热红外图**：海面船舶目标极小（可能仅数个像素），且依赖 B1/B2/B3 三波段通道信息；
- **开放场景**：用户可能临时提出训练类别之外的新类别；
- **遥感耕地图**：需要像素级区域分割与面积占比，而非目标框。

若只依赖单一模型，无法同时覆盖上述场景；即使已拥有多个模型，每次手工选择程序、填写参数、寻找结果文件，也会显著增加使用成本。而训练这些模型、运行大模型与视觉工具、管理实验过程，都对计算资源提出了超出个人电脑的要求。

2.2 设计原则

本作品的设计围绕四条原则展开：

1. **专业能力与任务组织解耦**：专用视觉模型负责“目标在哪里、是什么、有多少”，大语言模型负责“用户要做什么、该用哪个工具、如何解释结果”，二者各司其职、互不替代。
2. **可靠优先于炫技**：大模型不负责凭空检测目标，只负责在已验证的专用工具之间路由；工具返回的真实结构化结果才是结论的唯一依据。
3. **计算可承载、过程可复核**：把训练、推理、服务运行与结果归档放到算力平台上，通过作业记录、日志与结构化产物，让一次运行可以追溯、可以复现。
4. **平台为基座、智能体为外壳**：算力平台提供计算、存储、调度与记录能力，智能体负责组织任务与交互，平台能力通过智能体转化为普通用户可操作的科研工具。

2.3 技术路线选型

系统主干采用“JSON function-calling 工具注册表 + 编排器”的工程范式，起步阶段采用“零训练 + 提示词内专家方案”完成工具路由。理由如下：

- 三个（后续扩展为四个）视觉工具已独立建成，Agent 的核心职责是**意图理解 + 工具路由 + 结果汇总**，而非训练一个全能模型；
- 少数工具的路由任务通过精心设计的提示词与工具契约即可达到高准确率，无需引入微调训练的基础设施；
- JSON function-calling 相较文本式 ReAct 输出更稳定，配合确定性规则可进一步压制幻觉与格式错误。

3 总体技术架构

3.1 分层架构

系统自顶向下分为六层，由算力平台统一承载：

1. **交互层（Web 前端）**：图片上传 / 自然语言输入 / 结果展示 / 连续追问 / 批量切换 / 导出；

2. 智能体大脑 (Qwen3.5-9B · 条件视觉路由): 意图理解 → 判断是否需要看图 → 选择工具 → 补全参数, 依据工具真实返回结果生成自然语言结论;
3. 工具契约与守卫层: 工具注册表 (JSON Schema) + 参数校验 + 确定性纠偏规则;
4. 视觉工具层(专用模型): ir_detect_closed(无人机/地面红外 8 类闭集)、ir_detect_open(红外开放词汇)、ir_ship_detect_satellite(卫星三波段海面舰船)、ir_segment_cropland(遥感耕地分割);
5. 结果与导出层: 统一结果协议 → 自然语言结论 + 结果图 + 指标 + 风险提示, PNG / JSON / CSV / ZIP 导出;
6. 算力平台承载层 (107.ustc.edu.cn): Slurm 作业管理 / 共享存储 / 环境管理 / 资源监控 / 可复现交付。

3.2 各层职责

层	职责	关键技术
交互层	接收输入、呈现结果、承载对话与导出	对话式网页, 结论优先的信息层级
智能体大脑	理解任务、路由工具、解释结果	Qwen3.5-9B、条件视觉路由、多轮记忆
工具契约与守卫	统一工具描述、校验参数、纠偏高风险错误	function-calling JSON Schema、确定性规则
视觉工具层	实际执行检测/分割	YOLOv8、YOLO-World 等专用模型
结果与导出层	统一各工具结果、生成结论与交付物	统一结果协议、多格式导出
算力平台承载	提供计算、存储、作业与环境管理	Slurm、SCOW、共享目录、venv

3.3 一次请求的完整数据流

1. 用户上传图片 + 自然语言指令;
2. Qwen3.5 条件视觉路由 (明确任务只看文字 + 元数据; 模糊任务才读图);
3. 工具契约层校验参数, 工具守卫纠偏;

4. 调用对应视觉工具（本地加载模型推理）；
5. 返回结构化结果（类别/边界框/置信度/掩膜/面积占比）；
6. Qwen3.5 依据真实结果生成简洁自然语言结论与风险提示；
7. 前端展示 + 保存会话 + 可选导出（PNG/JSON/CSV/ZIP）。

其中，从“视觉工具推理”到“智能体后端服务”的每一段计算，都运行在算力平台分配的计算资源上，由 Slurm 作业统一调度、记录。

4 功能模块设计

4.1 交互层（Web 前端）

- 单图 / 多图 / 文件夹批量上传：统一输入方式，降低门槛；
- 自然语言任务输入：不设快捷按钮，所有任务交由 Agent 自主路由；
- 结论优先的结果页面：按“核心结论 → 结果图 → 关键指标 → 分析 → 风险提示”顺序展示，执行过程默认折叠；
- 批量逐图切换：左右翻页、缩略图定位、单图放大、综合分析与单图结论切换；
- 历史对话与新对话：会话保存上传图、指令、工具、结果与追问，可回看复用；
- 结果导出菜单：PNG、JSON、CSV、ZIP。

4.2 智能体大脑（路由层）

- 主模型：Qwen3.5-9B，推理精度 BF16，关闭长思考（`enable_thinking=False`）；
- 职责划分：路由阶段只输出简短 JSON，工具执行后再由总结模块生成自然语言结论，路由与回答分离；
- 条件视觉路由：明确指令仅用文字与文件元数据快速路由；模糊指令才把图像交给大模型判断；
- 多轮记忆：对话历史与工具观察结果追加回上下文，支持连续追问。

4.3 工具契约与守卫层

- **工具注册表：**以 function-calling JSON Schema 描述工具，新增工具只需注册、不改主循环；
- **参数校验：**缺失时不虚构路径，工具失败时返回结构化错误而非崩溃；
- **确定性工具守卫：**在大模型路由后增加确定性规则，纠正高风险错误——明确 RGB/可见光路由至开放词汇；明确卫星/B123/海上船舶路由至 TISD；封闭模型不支持的类别路由至开放词汇；未接入识别模型时不把检测冒充识别。

4.4 视觉工具层

工具	模型	能力	阈值/约定
ir_detect_closed	YOLOv8 (uav_ir_multiclass_v1)	无人机/地面红外 8 类闭集检测	conf=0.30，仅红外灰度图
ir_detect_open	YOLO-World (yolov8s-worldv2.pt)	开放词汇检测，临时指定类别	set_classes，RGB 兜底
ir_ship_detect_satellite	YOLOv8 (tisd_satellite_ship_v1)	卫星三波段海面舰船检测	conf=0.25，通道 [B3,B2,B1]
ir_segment_cropland	遥感耕地语义分割模型	耕地/非耕地分割与面积占比	叠加图 + 二值掩膜

统一单图输入：前端取消单独的“TISD 三波段模式”，用户直接上传合成后的 channel3 图像，由 Agent 根据自然语言与元数据判断工具。

4.5 结果与导出层

- **统一结果协议：**检测、分割、识别与批量任务共用同一结构 (schema_version / task_id / task_type / status / tool_name / model_name / metrics / summary / warning / result_images / mask_images / raw_results / runtime 等)；
- **结论生成：**单图任务由 Qwen 生成简洁结论；批量任务只调用一次 Qwen 生成综合分析，逐图用确定性模板；
- **导出规范：**ZIP 固定目录结构，处理中文文件名、同名冲突、部分失败保留成功结果等边界。

5 关键技术设计与技术难点

5.1 条件视觉路由（技术难点一）

难点：若每次路由前都让大模型读取图像，会带来更高显存占用、更长延迟、图像内容对文字指令的干扰，以及红外图被误判为 RGB 的风险。

方案：路由拆分为两条路径——明确任务仅用文字与文件元数据快速路由；模糊任务才启用图像理解辅助判断。

效果：100 条路由测试中，86 条仅用文字与元数据完成，14 条启用图像理解；平均路由延迟降至 0.67 秒。

5.2 高准确率的零训练工具路由（技术难点二）

难点：更强的大模型并不会在未经适配时自动获得更好的路由效果。Qwen3.5 初始版本路由准确率仅 74%。

方案：重新设计路由提示词、输出约束、工具契约与容错机制，经四轮优化：

阶段	路由准确率	JSON 一次解析	平均延迟	P95 延迟
Qwen3.5 初始版本	74%	79%	4.19 s	11.39 s
紧凑 JSON + 条件视觉	88%	100%	0.72 s	1.13 s
强化路由提示词	93%	100%	0.68 s	0.97 s
加入确定性工具守卫	99%	100%	0.67 s	0.94 s

关键措施：路由输出与最终回答分离、路由输出长度限制（192 tokens）、JSON 解析失败自动重试、确定性工具契约守卫。

5.3 从一次性工具到连续对话 Agent（技术难点三）

难点：原系统每次上传一张图、输入一句话后流程即结束，对同一结果继续追问会重复调用检测工具。

方案：引入会话历史与结果记忆，同一会话中若未上传新图、未明确要求重检，则复用上一轮结果直接作答；仅在新图、明确重检、修改阈值或新任务时重新调用工具。

5.4 批量处理与真实进度（技术难点四）

难点：长任务在页面长时间停留在“准备中”，用户无法判断是否卡住；批量结果缺少整体结论。

方案：新增后端真实进度接口，按实际完成图片数更新进度，区分“视觉工具已处理完成”与“大模型正在组织结论”两个阶段；批量默认显示聚合结论，支持单图详情与综合分析切换。

5.5 性能优化（技术难点五）

难点：10 张图批量任务初测总耗时 45.7 秒，瓶颈为每图重复加载模型、每图单独调用 Qwen、服务启动后才加载大模型。

方案与效果：Qwen 后台预热、YOLO 模型常驻缓存、批量只做一次大模型总结、限制总结长度。

测试状态	10 张图总耗时
优化前	45.741 s
首次优化运行（Qwen 已热，YOLO 冷启动）	12.633 s
模型全部预热	9.502 s
保留一次 Qwen 综合分析（演示采用）	预计 12~14 s

速度提升来自工程流程优化，不通过降低分辨率或更换模型牺牲检测效果。

5.6 算力平台开发运行机制的适配（技术难点六）

难点：算力平台与“单机直接跑脚本”不同——登录节点与计算节点分离，GPU 计算需通过作业调度获得，路径与权限受平台规则约束。

方案：登录节点负责准备文件与提交作业，GPU 计算在获分配的计算节点执行；通过 Slurm 描述资源需求与运行入口；数据路径使用共享工作目录与配置项；环境通过 venv 独立配置；重要产物保存在共享目录。详见第六章。

6 算力平台在本作品中的应用

算力平台是本作品的**计算基座与运行载体**，贯穿“训练、推理、服务运行、过程记录、可复现交付”的全流程。

6.1 为什么需要算力平台

科研环节	个人电脑的瓶颈	算力平台提供的能力
模型训练	显存不足、训练时间长、占用整机	按需申请 GPU (RTX 5090 / A100), 训练与日常分离
大模型运行	Qwen3.5-9B 需约 19.4 GB 显存, 个人显卡难承载	在平台计算节点上运行大模型与视觉模型
环境复现	换机器就重装环境、改路径	venv 独立环境 + requirements 锁定依赖
数据与模型共享	文件散落各机器	共享工作目录, 多节点访问同一套文件
运行追溯	只有程序日志与手工截图	Slurm 作业编号、状态、资源分配、起止时间
结果可复现	依赖个人记忆与配置	一键脚本 + 部署包 + 运行数据说明

6.2 平台资源的实际部署

组件	说明
平台入口	107.ustc.edu.cn (SCOW 网页终端 / 获授权 SSH 入口)
作业调度	Slurm (sbatch 提交、squeue 查看、sacct 查询、sinfo 查看分区)
登录节点	tradmin-02 (准备文件、提交作业)
计算节点	anode01 / anode02 (GPU 推理执行)
比赛分区	P107-RTX5090 (RTX 5090, 32 GB)、P107-A100 (A100)
运行环境	Python 3.12 venv + torch 2.14.0+cu130 + ultralytics 8.4.117 (CUDA 13.0)
项目目录	~/ir_rs_agent_107/ (代码 + 权重 + 样例 + 结果)

6.3 Slurm 作业管理

本作品的核心程序在平台上以 Slurm 作业的形式运行。这种“作业化”方式带来三点价值：

1. **资源申请有记录：**申请了多少资源、在哪个分区、哪个节点、何时起止，均有据可查；
2. **计算与交互分离：**登录节点只负责准备与提交，真正的 GPU 计算在获分配的计算节点执行；
3. **状态可判断：**通过 PENDING、RUNNING、COMPLETED、FAILED 区分任务阶段，再结合日志与结果判断业务是否成功。

一次 GPU 推理复测作业记录如下：

字段	值
JobID	56601
JobName	ir_rs_infer
Partition	P107-RTX5090
NodeList	anode02
GPU	NVIDIA GeForce RTX 5090
环境	torch 2.14.0+cu130, cuda True
ExitCode	0（成功）

6.4 共享存储

本项目将代码、模型权重、测试图片与输出结果统一组织到共享工作目录，任务分配到不同计算节点时也能访问同一套文件。重要结果保存在共享目录、临时文件与正式产物分离。

6.5 环境管理与依赖核验

借助平台的软件环境管理能力，为项目建立独立 venv，核验 Python、PyTorch、CUDA 与模型依赖，通过 requirements 文件锁定依赖版本，使“在平台上重新建一次环境”成为可重复的操作。

6.6 资源监控

作业在计算节点内通过 `nvidia-smi` 采样 GPU 状态，用 GPU UUID 精确锁定本作业分配的设备。采样字段包括时间戳、GPU 序号、UUID、显存使用/总量、利用率、功耗与进程数。

指标	实测值
采样最大显存占用	1560 MB（约 1.5 GB，YOLO 模型驻留）
显存总量	32607 MB（32 GB）
采样 GPU 利用率	0-1%（检测耗时极短）
采样功耗	58-75 W

这些数据用于判断资源配置是否合理，把申请值与实际峰值分开记录，不把整节点占用全部归入本项目。

6.7 一键复现与交付闭环

完整部署流程已固化为可复现脚本，核心五步：

1. 访问：校园网/VPN → SSH 或网页终端登录集群；
2. 上传：网页文件管理上传 `deploy_107.tar.gz`；
3. 建环境：`venv + requirements-107.txt` 安装依赖；
4. 提交：`sbatch run_infer.sh`（分区 P107-RTX5090，1×GPU）；
5. 采集：作业内 GPU 采样、日志与结构化结果归档。

提供一键演示脚本 `demo.sh`，自动完成“提交 → 等待 → 打印日志/结果/账目/GPU 采样”全流程。详细运行数据见《运行数据说明 _107 平台.md》。

6.8 算力平台带来的整体价值

算力平台在本作品中承担了计算供给、作业调度、共享存储、环境管理、资源监控、可复现交付六项关键职能，把数据、模型、作业与结果统一收拢在平台上，形成有记录、可追溯、可复现的工程化闭环；智能体则把这份平台能力，转化为普通用户用自然语言即可操作的科研工具。

7 创新点总结

1. **“大脑 + 工具”解耦的工具编排型智能体**：以零训练的大模型路由替代“训练一个全能模型”，用 JSON function-calling 工具注册表统一接入多个已验证的专用视觉模型。
2. **条件视觉路由**：视觉理解只用于真正需要的模糊任务，将路由准确率提升至 99%、平均延迟降至 0.67 秒。
3. **确定性工具契约守卫**：在大模型路由之外增加规则护栏，压制幻觉与高风险误路由，不虚构识别结果。
4. **从一次性工具到连续对话 Agent**：基于结果记忆的连续追问与历史会话，避免重复计算、保证结果稳定。
5. **学科交叉创新——红外遥感 × 算力平台**：以本科生算力平台为项目全程开发与运行环境，用 Slurm 作业化、共享存储与资源监控组织科研流程。
6. **可复现的工程化交付**：环境锁定、一键脚本、部署包与运行数据说明齐备，别人按说明即可重复运行。

8 复用价值与可扩展性

本作品提供一条可参考的六步范式：**定义需求 → 整理资产 → 平台运行 → 工具封装 → 智能体接入 → 验证交付**。其他科研项目可将红外检测器替换为细胞计数、实验曲线拟合、材料性质预测或科学计算程序——专业方法需各自验证，但共享目录组织、环境管理、作业执行、工具接口与结果归档的组织方式可以沿用。

系统采用工具注册表设计，新增专业工具只需注册其 JSON Schema，无需改动主循环，具备良好的可扩展性。对本科生教学科研而言，本作品既降低了“用深度学习处理红外影像”的使用门槛，也提供了一条“在算力平台上开展自己的科研项目、再组织成智能体”的可复制路径。